






COVARRUBIAS OSUNA DAIRY KARIME

AI GENERATIVE MODELS

AI (ARTIFICIAL INTELLIGENCE)

La Inteligencia Artificial (IA) es una tecnología que permite a las computadoras y máquinas simular el aprendizaje humano, la comprensión, la resolución de problemas, la toma de decisiones, la creatividad y la autonomía.

AI MODELS

Es una IA entrenada con un conjunto de datos para reconocer patrones y realizar tareas específicas.


GENERATIVE AI

Es una IA que puede generar contenido nuevo, como texto, imágenes u otros medios. El contenido se genera a partir de las aportaciones del usuario.



1. AI GENERATIVE MODELS

Un modelo generativo de IA es un modelo de machine learning diseñado para crear nuevos datos que sean similares a sus datos de entrenamiento. Estos aprenden patrones y distribuciones de los datos de entrenamiento, y luego aplican esos entendimientos para generar contenido novedoso en respuesta a nuevos datos de entrada.



2. TIPOS DE MODELOS GENERATIVOS

2.1 GAN (REDES GENERATIVAS ADVERSATIVAS)

Funcionan con **dos redes neuronales** que compiten entre sí:

- Generador (G): crea datos falsos.
- Discriminador (D): distingue entre datos reales y falsos.

Ambas compiten en un juego:

- El generador intenta engañar al discriminador.
- El discriminador mejora su capacidad para detectar falsos.

Con el tiempo, el generador mejora hasta producir datos muy realistas. Se usan principalmente en generación de imágenes, transferencia de estilo y aumento de datos.

2.1.2 ENTRENAMIENTO DE GAN

- El éxito depende del equilibrio entre G y D.
- Problemas comunes durante el entrenamiento:
 - Colapso de modos: el generador produce poca variedad de datos.
 - Desvanecimiento de gradientes: el aprendizaje se vuelve lento o se detiene.
 - Inestabilidad y divergencia.
- Soluciones propuestas:
 - Coincidencia de características.
 - Discriminación por minilotes.
 - Normalización por lotes.
 - Penalización de gradiente y restricciones de Lipschitz.

2.1.3 DESAFIOS Y LIMITACIONES

- Entrenamiento difícil de estabilizar.
- Alta demanda de recursos computacionales.
- Dificultad para evaluar la calidad de los resultados.
- Vulnerabilidad ante ataques adversarios.
- Se requiere investigación para mejorar:
 - Estabilidad.
 - Robustez.
 - Selección de hiperparámetros.

2.2 VAE (AUTOCODIFICADORES VARIACIONALES)

- Aprenden una representación simplificada de los datos en un espacio latente. Utilizan un codificador para comprimir la información y un decodificador para reconstruirla. Se emplean para generar datos similares a los originales y entender sus características principales. Los VAE combinan autoencoders y modelado probabilístico.
- Aprenden representaciones en un espacio latente continuo.
- Componentes principales:
 - **Codificador**: transforma los datos en una distribución de probabilidad en el espacio latente.
 - **Decodificador**: genera nuevos datos a partir del espacio latente.
- Permiten:
 - Generar nuevos datos.
 - Interpolación entre muestras.
 - Representaciones compactas.
- Se optimiza mediante el ELBO, que equilibra:
 - Precisión de reconstrucción.
 - Similitud entre distribuciones latentes.

2.2.2 ENTRENAMIENTO DE VAE

- Se entrenan mediante aprendizaje no supervisado.
- Usan la técnica de reparametrización para permitir retropropagación en variables aleatorias.
- Optimizan el ELBO mediante métodos como gradiente estocástico (ej. Adam).
- Uso de minilotes para mejorar eficiencia en grandes datasets.
- Permiten modelar distribuciones complejas y generar datos realistas.

2.2.3 DESAFIOS Y LIMITACIONES

- Resultados a veces borrosos en comparación con GAN.
- Dificultad para modelar datos muy complejos o multimodales.
- Dependencia de una buena elección del espacio latente.
- Investigación actual busca mejorar:
 - Calidad de las muestras.
 - Capacidad de representación.
 - Estabilidad del entrenamiento.

2.3 MODELO DE DIFUSION

Los modelos de difusión generan nuevos datos agregando ruido de forma gradual a los datos originales hasta que pierden su forma. Luego, aprenden a invertir este proceso, eliminando el ruido paso a paso para crear datos nuevos que sean coherentes y similares a los originales.

Arquitecturas más usadas:

- **U-Net**: captura características a diferentes escalas.
- **Transformers**: modelan dependencias globales.
- **Arquitecturas híbridas**: combinan ventajas de ambas.

2.3.2 ENTRENAMIENTO DE MODELOS DE DIFUSION

- Aprenden mediante un proceso de difusión directa (añadir ruido) y difusión inversa (quitar ruido).
- Se optimizan usando máxima verosimilitud y ELBO.
- **Ventajas frente a GAN:**
 - Entrenamiento más estable.
 - Mayor diversidad de resultados.
- **Desventaja:** Generación más lenta debido a múltiples pasos secuenciales.

2.3.3 DESAFIOS Y LIMITACIONES

- Alto costo computacional.
- Proceso de generación lento.
- Espacio latente menos interpretable que en GAN.
- Se investiga mejorar:
 - Velocidad de muestreo.
 - Eficiencia del entrenamiento.
 - Escalabilidad del modelo.

2.4 MODELOS HIBRIDOS

- Combinan VAE, GAN y otros modelos para aprovechar sus ventajas.
- Objetivo:
 - Mayor calidad de generación.
 - Mejor estabilidad de entrenamiento.
 - Representaciones latentes más útiles.

VAE-GAN

- Une la estructura latente del VAE con la calidad visual de GAN.
- El discriminador ayuda a mejorar la nitidez de las imágenes.
- Reduce el problema de imágenes borrosas del VAE.

ALI / BiGAN

- Aprende generación e inferencia al mismo tiempo.
- Mejora la representación del espacio latente.
- Reduce el problema de colapso modal.

InfoVAE

- Usa principios de teoría de la información.
- Maximiza la información entre datos y variables latentes.
- Mejora la calidad y significado de las representaciones.

SS-AVL

- Combina VAE + GAN + aprendizaje autosupervisado.
- Usa un espacio latente estructurado.
- Mejora estabilidad y capacidad de representación.

2.4.3 DESAFIOS Y LIMITACIONES

- Entrenamiento complejo.
- Inestabilidad heredada de GAN.
- Dificultad para generar resultados coherentes globalmente.
- Necesidad de más investigación.

2.5 REDES NEURONALES RECURRENTES

Las redes neuronales recurrentes (RRN), las redes neurales de término de memoria corto – largo (TMCL) y las redes neuronales de unidad recurrente con compuertas (URC) dominaron la generación de lenguaje antes de la aparición de los Transformers.

Por ejemplo, Mikolov (2010) y Sutskever (2011) demostraron la capacidad de las RNR y TMCL para generar texto coherente y de longitud moderada.

Pueden generar texto coherente, pero tienen problemas con contextos largos, menor calidad de lenguaje y entrenamiento más lento.

2.6 MODELOS AUTORREGRESIVOS


Predicen el siguiente dato basándose en los datos anteriores de la secuencia.
Los Modelos Transformers destacan en procesamiento de lenguaje natural (PLN) por su capacidad de entender el contexto.

Aplicaciones:

- Chatbots y asistentes virtuales.
- Análisis de sentimientos.
- Reconocimiento de voz.
- Resumen de texto.
- Generación y depuración de código.
- Pronóstico de series temporales (finanzas, clima).
- Aprendizaje por refuerzo y clasificación.

Ejemplos de modelos:

- GPT (OpenAI)
- Claude (Anthropic)
- Llama (Meta)
- Gemini (Google)
- Granite (IBM)



2.6.1 MODELOS DE TRANSFORMADORES

- Introducidos en 2017, superaron a las RNN en el manejo de secuencias.
- Procesan todos los elementos de la secuencia al mismo tiempo (procesamiento paralelo).
- Utilizan autoatención para identificar la importancia de cada palabra según el contexto.
- Permiten entender relaciones entre palabras incluso si están muy separadas.

Ventajas:

- Entrenamiento más rápido y eficiente
- Mejor comprensión del lenguaje
- Alto rendimiento en:
 - Generación de texto
 - Traducción automática
 - Resumen de texto.

2.6.2 TIPOS

Bidireccionales (BERT)

- Analizan el contexto completo de una oración (izquierda y derecha).
- Usan Masked Language Modeling (MLM).
- Muy útiles en:
 - comprensión de texto
 - clasificación
 - análisis semántico

Generativos Preentrenados (GPT)

- Modelos autorregresivos que predicen el siguiente token.
- Generan texto coherente según estilo y contexto.
- Usados en:
 - Chatbots
 - Generación de texto.
 - Programación.

Bidireccionales + Autorregresivos (BART)


- Combina BERT + GPT.
- Codificador bidireccional + decodificador generativo.
- Útil para:
 - Resumen automático.
 - Traducción.
 - Corrección de texto.

Transformers Multimodales

- Procesan texto + imágenes u otros datos.
- Ejemplos: ViLBERT, VisualBERT.
- Usados en:
 - Análisis de imágenes con texto.
 - Preguntas sobre imágenes.

Vision Transformers (ViT)

- Adaptan transformers para imágenes.
- Dividen la imagen en parches y aplican autoatención.
- Usados en:
 - Clasificación de imágenes.
 - Visión por computadora.




USO DE MODELOS GENERATIVOS DE LENGUAJE EN LA EDUCACION SUPERIOR



El uso de modelos generativos de lenguaje en la educación superior ha generado tanto oportunidades como preocupaciones. Por un lado, pueden mejorar el aprendizaje y las metodologías educativas; por otro, han despertado inquietudes sobre el plagio y la deshonestidad académica, incluso llevando a algunas instituciones a restringir su uso.

Uno de los principales desafíos es su impacto en la evaluación, ya que los estudiantes podrían depender de estas herramientas para realizar tareas, dificultando medir su aprendizaje real. Además, existe resistencia por parte de algunos docentes para adaptarse a estos cambios.

También se destaca el riesgo de que estos modelos generen información incorrecta o poco confiable, lo que hace necesario validar cuidadosamente su uso en contextos educativos.



3. HALLUCINATIONS

Todos los modelos de IA no son perfectos. Los resultados suelen tener imprecisiones, a lo que se le conoce como alucinaciones.

Las **alucinaciones** son resultados que arroja la IA y que no son ciertos. Esas imprecisiones pueden ser desde errores menores, como una frase sin sentido, hasta distorsiones considerables.



CONCLUSION

Los modelos generativos de IA, como los Transformers, GAN, VAE y modelos de difusión, han mejorado notablemente la capacidad de generar texto, imágenes y otros datos. En educación superior ofrecen grandes beneficios, pero también plantean retos como la confiabilidad de la información y la integridad académica. Su uso debe ser responsable para aprovechar sus ventajas sin descuidar sus limitaciones.

FUENTES

Yazdani, S., Singh, A., Saxena, N., Wang, Z., Palikhe, A., Pan, D., ... & Zhang, W. (2025). Generative AI in depth: A survey of recent advances, model variants, and real-world applications. *Journal of Big Data*, 12(1), 230.

Stryker, C., & Kavlakoglu, E. (2025, 27 noviembre). Inteligencia artificial. IBM Think. <https://www.ibm.com/mx-es/think/topics/artificial-intelligence>

Belcic, I. (2025, 26 noviembre). Modelo generativo. IBM Think. <https://www.ibm.com/mx-es/think/topics/generative-model>

Amazon Web Services. (s. f.). ¿Qué es la IA generativa? Amazon Web Services, Inc. <https://aws.amazon.com/es/what-is/generative-ai/>

Amazon Web Services. (s. f.-b). ¿Qué son los transformadores en la inteligencia artificial? Amazon Web Services, Inc. <https://aws.amazon.com/es/what-is/transformers-in-artificial-intelligence/>

FUENTES

Colón, R. L., Ayala, L. C., & Rodríguez, P. R. (2023). Impacto de los modelos generativos de lenguaje de inteligencia artificial en la educación superior. *Tlatemoani: revista académica de investigación*, 14(44), 19-40.

Coursera | Online Courses From Top Universities. Join for Free. (s. f.). Coursera.
<https://www.coursera.org/programs/fundamentos-de-ia-google-2024-liznu/learn/google-ai-essentials?collectionId=cfuDy>

THANK YOU